

Exploratory Data Analysis (EDA)

A análise exploratória de dados consiste em explorar, resumir e visualizar os dados através de uma série de etapas. Com essas etapas buscamos entender a estrutura, testar nossas hipóteses, identificar anomalias e encontrar padrões e relações entre *features*. A análise exploratória de dados tem algumas variações e cada uma possui objetivos claros a atingir, sendo elas: a análise univariada, que tem o objetivo de entender a distribuição e variação de uma única *feature*; bivariada, que serve para estudar o relacionamento entre duas variáveis; e a análise multivariada, que foca nas interações entre múltiplas variáveis. Neste documento, descreveremos quais análises foram realizadas e as informações obtidas.


Inicialmente nosso objetivo é treinar um algoritmo de classificação para determinar se uma notícia é verdadeira ou falsa. Para podermos fazer isso escolhemos o dataset (Fake.br corpus) encontrado no github.

Após realizar o carregamento dos dados fornecidos neste dataset começamos a pré-processar esses textos usando uma biblioteca chamada Spacy, com ela pudemos extrair os metadados gramaticais para analisar a seguir.

Nosso primeiro passo foi particionar o dataset em bloco de 200 para conseguirmos processar os dados, porém mesmo assim o documento ainda estava denso para fazer a extração então foi necessário particionar em 16 textos para podermos realizar o processamento. De cada trecho foram extraídas informações da categorização de cada palavra, Part Of Speak (POS), e o tipo de dependência sintática (DEP) que ela possui na sentença em que se encontra. Para POS, extraímos as categorias: ADJ (Adjetivo), ADP (Adposição - Preposição / Pós-posição), ADV (Advérbio), AUX (Verbo Auxiliar), CCONJ (Conjunção Coordenativa), DET (Determinante / Artigos), INTJ (Interjeição), NOUN (Substantivo), NUM (Numeral), PART (Partícula), PRON (Pronome), PROPN (Nome Próprio), PUNCT (Pontuação), SCONJ (Conjunção Subordinativa), SYM (Símbolo), VERB (Verbo Principal), X (Outro / Desconhecido), SPACE (Espaço em branco / Quebra de linha); já para DEP, as classificações foram: **ROOT** (Raiz da sentença), **nsubj** (Sujeito nominal), **obj** (Objeto direto), **iobj** (Objeto indireto), **amod** (Modificador adjetivo), **advmod** (Modificador adverbial), **det** (Determinante), **case** (Marcador de caso / Preposição), **conj** (Elemento conjugado), **cc** (Conjunção coordenativa), **acl** (Modificador de oração adjetiva), **advcl** (Modificador de oração adverbial), **appos** (Aposto), **compound** (Palavra composta), **flat** (Nome composto), **fixed** (Expressão gramatical fixa), **nmod** (Modificador nominal), **nummod** (Modificador numeral), **mark** (Marcador de subordinação), **punct** (Pontuação pontual). Todos os dados extraídos foram contabilizados como proporção ou porcentagem em relação ao total no texto e não como números absolutos.

Para algumas análises mais visuais foram utilizados alguns gráficos como:


Matriz de correlação de Spearman: Nela utilizamos as 54 features obtidas e medimos seu nível de correlação. Algo positivo que encontramos com isso foi o fato que algumas características gramaticais se repetem entre as famílias e/ou apresentam uma correlação muito alta. Assim, já tínhamos uma noção de quais features teriam o potencial de ser removidas futuramente.




Como apresentado no heatmap acima identificamos uma alta correlação entre campos das duas famílias e pudemos identificar como campos repetidos.

Ex: POS_DET = DEP_det


Variance Inflation Factor (VIF): o gráfico gerado mostra o comportamento das features e quais estão destoantes das outras métricas, logo podemos isolá-las para um tratamento adequado.



Aqui identificamos o comportamento de features muito acima de outras e pudemos explorar a relevância e comportamento. Ex: DEP_nmod.




Pair Grid: Nesse gráfico podemos entender os agrupamentos dos dados e verificar entender os outliers com mais facilidade, com isso podemos validar alguns parâmetros e se de fato esses comportamentos estão correspondendo as hipóteses ou se precisaremos fazer outras análises considerando esses dados espalhadas.



No gráfico acima mostramos a diferença de comportamento entre verdadeiro e falso onde em sua grande maioria as notícias verdadeiras possuem um comportamento muito mais previsível que as falsas.


Histograma: O gráfico de barras nos ajudou a entender o comportamento das features para os grupos de verdadeiras e falsas separadamente, isso foi muito útil para confirmar os estudos sobre estrutura gramatical diferente em textos de informações verídicas e falsas.



Aqui podemos visualizar que algumas features não possuem um comportamento significativo como POS_PART e POS_INTJ logo pudemos retirar dos dados que usaremos para processar e treinar modelo.

Boxsplot: Este gráfico foi utilizado para visualizar de maneira mais simples onde estão localizados os agrupamentos mais densos dos textos em cada feature com as notícias verdadeira das falsas além de encontrar outliers.

Box plots por classe (página 1)



Como podemos visualizar acima o mesmo comportamento destacado no histograma, porém aqui conseguimos visualizar o comportamento dos outliers além de ter uma apresentação mais simplificada da densidade de textos.